



Cours Recherche D'information (Information Retrieval)

3^{ème} Année Licence

Option : ISIL



2023-2024



Mme Z.LAAREDJ

Extension du modèle booléen (Extended Boolean Model)

Plan

- Introduction
- Le modèle booléen étendu
- Appariement dans le modèle booléen étendu
- Avantages et Inconvénients du modèle booléen étendu
- Le modèle booléen basé sur des ensembles flous
- Avantages et Inconvénients du modèle booléen basé sur les ensembles flous

Introduction

- Dans le modèle booléen de base tous les termes dans un document ou dans une requête étant pondérés de la même façon simple (0 ou 1).
- Pour pallier à ces inconvénients, une extension de modèle booléen nommée « booléen étendu » a été proposée pour prendre en compte la pondération des termes.
- Prendre en compte l'importance des termes dans les documents et dans la requête.
- Possibilité d'ordonner les documents sélectionnés

Introduction

- Dans ce contexte deux modèles ont été proposé
 - Modèle booléen étendu- extended boolean model
 - Modèle flou- fuzzy based model (basé sur la logique floue)

Le modèle booléen étendu

- C'est une extension qui intègre le principe de pondération
- Chaque terme que ce soit dans le document ou dans la requête à un poids.
- Combinaison des modèles booléen et vectoriel dont :
 - Document : liste de termes pondérés
 - Requête booléenne
 - Utilisation des distances algébriques pour mesurer la pertinence d'un document vis-à-vis à d'une requête.

Le modèle booléen étendu

➤ Le modèle de connaissances

- $T = \{t_i\}, i \in [1, .. n]$, Les t_i indexent les documents
- Un document (D_j) de $D, j \in [1,..m]$ est représenté par :
 - Une formule logique de la même manière que le modèle booléen
 - Une fonction poids $W_{tiDj} : t \in [0,1]$, qui a pour chaque terme de T donne le poids de ce terme dans D . Le poids vaut 0 pour un terme non présent dans le document.

Appariement dans le modèle booléen étendu

➤ **La fonction de correspondance** : pour le cas du modèle Booléen étendu, la fonction de pertinence ou la correspondance RSV (d_j, q) entre une requête et un document est déterminée de la façon suivante:

- $d_j = (w_{1j}, w_{2j}, \dots, w_{tj})$
- q : requête à deux termes (t_1, t_2) ou
 - $q_{and} = t_1 \text{ et } t_2$
 - $q_{or} = t_1 \text{ ou } t_2$

Appariement dans le modèle booléen étendu

- Dans le cas où la requête contient l'opérateur AND :
qand = t1 et t2, la fonction de correspondance est la suivante :

$$R(d_j, t_1 \wedge t_2) = 1 - \sqrt{\frac{(1 - w_{1j})^2 + (1 - w_{2j})^2}{2}}$$

- Dans le cas où la requête contient l'opérateur OR : qor = t1 ou t2, la fonction de correspondance est la suivante :

$$R(d_j, t_1 \vee t_2) = \sqrt{\frac{w_{1j}^2 + w_{2j}^2}{2}}$$

Appariement dans le modèle booléen étendu

➤ **Généralisation** : L'appariement requête-document est déterminé par les relations introduites dans le modèle p-norm basées sur les p-distances, avec $1 \leq p \leq \infty$. La valeur de p est indiquée au moment de la requête. Si m est le nombre de termes dans la requête, les fonctions de similarité se calculent comme suit :

- Distance euclidienne à plusieurs dimensions
- Utilisation de la p-norm

Appariement dans le modèle booléen étendu

➤ Considérons que:

■ $d_j = (w_{1j}, w_{2j}, \dots, w_{tj})$

■ q : requête composée de m termes $(t_1, t_2, \dots, t_m)$

$$RSV(d_j, q_{or}) = \left(\frac{w_{1j}^p + w_{2j}^p + \dots + w_{mj}^p}{m} \right)^{1/p}$$

$$RSV(d_j, q_{and}) = 1 - \frac{((1 - w_{1j})^p + (1 - w_{2j})^p + \dots + (1 - w_{mj})^p)^{1/p}}{m^{1/p}}$$

$$RSV(d_j, q_{not}) = 1 - RSV(d_j, q)$$

Appariement dans le modèle booléen étendu

- Si $p = 1$ alors (on retrouve le modèle vectoriel)

- $RSV(d_j, q_{or}) = RSV(d_j, q_{and})$

- Si $p = \infty$ alors (modèle booléen)

- $RSV(d_j, q_{or}) = \max (w_{xj})$

- $RSV(d_j, q_{and}) = \min (w_{xj})$

- $p=2$ correspond à la distance euclidienne, semble être le meilleur

choix

Appariement dans le modèle booléen étendu

- Si les documents et les termes sont pondérés :

$$\mathbf{d}_j = (w_{1j}, w_{2j}, \dots, w_{tj})$$

Si la requête et les documents sont pondérés

$$\mathbf{q} = (q_1, q_2, \dots, q_m)$$

$$RSV(dj, q_{or}) = \left(\frac{\sum q_i^p * w_{ij}^p}{\sum q_i^p} \right)^{1/p}$$

$$RSV(dj, q_{and}) = 1 - \left(\frac{\sum q_i^p * (1 - w_{ij})^p}{\sum q_i^p} \right)^{1/p}$$

Avantages et Inconvénients du modèle booléen étendu

- Modèle puissant
- Calcul complexe
- Problème de distributivité
 - $q1 = (t1 \text{ OU } t2) \text{ ET } t3$
 - $q2 = (t1 \text{ ET } t3) \text{ OU } (t2 \text{ ET } t3)$
 - $RSV(q1, d) \neq RSV(q2, d)$

Modèle booléen basé sur des ensembles flous

- Des modèles fondés sur la théorie des ensembles flous (Kraft et Buell 1983) et considérés aussi comme une extension de la version classique du modèle booléen.
- Dans les ensembles flous, l'appartenance est mesurée par un degré variant entre 0 et 1
 - $0 \rightarrow$ non appartenance
 - $1 \rightarrow$ appartenance complète

Modèle booléen basé sur des ensembles flous

➤ Un document est représenté comme un ensemble de termes pondérés comme suit:

➤ $\mathbf{d} = \{..., (t_i, a_i), ...\}$ tel que t_i est le terme, a_i est le poids associé au terme t_i

➤ **Le degré de correspondance (évaluation d'une requête) :**

■ **Evaluation 1: [Zadeh]**

$$R(d, t_i) = a_i$$

$$R(d, q_1 \wedge q_2) = \min(R(d, q_1), R(d, q_2)).$$

$$R(d, q_1 \vee q_2) = \max(R(d, q_1), R(d, q_2)).$$

$$R(d, \neg q_1) = 1 - R(d, q_1).$$

Modèle booléen basé sur des ensembles flous

➤ Un document est représenté comme un ensemble de termes pondérés comme suit:

➤ $\mathbf{d} = \{..., (t_i, a_i), ...\}$ tel que t_i est le terme, a_i est le poids associé au terme t_i

➤ **Le degré de correspondance (évaluation d'une requête) :**

■ **Évaluation 2: [Lukaswicz]**

$$R(d, t_i) = a_i$$

$$R(d, q_1 \wedge q_2) = R(d, q_1) * R(d, q_2).$$

$$R(d, q_1 \vee q_2) = R(d, q_1) + R(d, q_2) - R(d, q_1) * R(d, q_2).$$

$$R(d, \neg q_1) = 1 - R(d, q_1).$$

Avantages et Inconvénients du modèle booléen basé sur les ensembles flous

➤ Avantages

- Atténuer certaines limitations telles que l'ambigüité des requêtes, l'imprécision dans le processus d'indexation ainsi que l'écart de pertinence entre les documents résultats.

➤ Inconvénients

- Ne permet pas d'offrir un ordonnancement à l'ensemble des résultats.

Références bibliographiques

- [1] <https://www.irit.fr/~Mohand.Boughanem/slides/RI/chap4-mod-bool-vect.pdf>
- [2] https://constellation.uqac.ca/id/eprint/4648/1/Hannech_uqac_0862D_10472.pdf